

强化学习课程笔记整理

1 第一讲：强化学习基本概念

强化学习的核心框架基于马尔可夫决策过程，包含以下基础构成要素：

定义

状态 (State): 状态是智能体 (Agent) 对自身所处环境的表征。

- 状态空间 (State Space): 所有可能状态构成的集合，记为 $\mathcal{S}$ ；任意单个状态记为 s ，满足 $s \in \mathcal{S}$ 。

定义

动作 (Action): 智能体在特定状态下可执行的操作。

- 状态 s 对应的动作空间记为 $\mathcal{A}(s)$ ；任意单个动作记为 a ，满足 $a \in \mathcal{A}(s)$ 。

定义

状态转移 (State Transition): 智能体在状态 s 执行动作 a 后，环境转移到下一状态的随机过程，由条件概率描述：

$$p(s' | s, a) = \mathbb{P}(S_{t+1} = s' | S_t = s, A_t = a)$$

其中 S_t 、 A_t 分别表示第 t 决策步的状态与动作。

定义

策略 (Policy): 策略定义了智能体的行为规则，即每个状态下的动作选择方式，记为 π 。

- 随机策略表示为条件概率分布 $\pi(a | s)$ ，含义为：处于状态 s 时选择动作 a 的概率，满足归一性

$$\sum_{a \in \mathcal{A}(s)} \pi(a | s) = 1.$$

定义

奖励 (Reward): 奖励是环境向智能体反馈的标量信号，是强化学习的优化目标来源。

- 即时奖励：在状态 s 执行动作 a 后获得的期望奖励记为 $r(s, a)$ ，即

$$r(s, a) = \mathbb{E}[R_{t+1} | S_t = s, A_t = a],$$

其中 R_{t+1} 是第 $t+1$ 步的随机奖励变量。

定义

折扣回报 (Discounted Return): 回报是从当前时刻起, 未来所有奖励的累积和; 引入折扣因子以平衡即时奖励与长期奖励。

- 折扣因子 $\gamma \in [0, 1)$, 保证无限步交互下回报有限, 取值越小表示智能体越看重即时奖励。
- 第 t 步的折扣回报定义为:

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}.$$

回报 G_t 是依赖于轨迹的随机变量。

定义

回合与任务分类:

- 回合 (Episode):** 具有明确终止状态的有限长度交互轨迹。
- 回合式任务 (Episodic Tasks):** 任务存在终止状态, 交互过程可划分为独立的回合。
- 持续性任务 (Continuing Tasks):** 任务无终止状态, 交互过程无限持续。

定义

马尔可夫决策过程 (MDP): 马尔可夫决策过程是强化学习的标准数学模型, 核心满足**马尔可夫性**: 下一状态仅由当前状态和动作决定, 与历史状态无关。

$$\mathbb{P}(S_{t+1} \mid S_t, A_t, S_{t-1}, A_{t-1}, \dots) = \mathbb{P}(S_{t+1} \mid S_t, A_t).$$

完整的 MDP 由五元组 $(\mathcal{S}, \mathcal{A}, p, r, \gamma)$ 构成:

- 状态空间 $\mathcal{S}$
- 动作空间 $\mathcal{A}$
- 状态转移概率函数 $p(s' \mid s, a)$
- 期望奖励函数 $r(s, a)$
- 折扣因子 γ

2 第二讲：贝尔曼方程

贝尔曼方程是强化学习的核心方程，刻画了价值函数的递归关系，是策略评估与优化的基础。

1. 状态价值函数

在策略 π 下，状态价值函数定义为：从状态 s 出发，始终遵循策略 π 交互所能获得的期望折扣回报：

$$v_{\pi}(s) = \mathbb{E}_{\pi} [G_t \mid S_t = s].$$

- $v_{\pi}(s)$ 是状态 s 的函数，取值完全依赖于策略 π ；
- 价值函数本质是回报的期望，用于量化不同状态的长期优劣程度。

2. 贝尔曼期望方程推导

利用回报的递归分解关系 $G_t = R_{t+1} + \gamma G_{t+1}$ ，代入状态价值函数的定义展开：

$$\begin{aligned} v_{\pi}(s) &= \mathbb{E}_{\pi} [G_t \mid S_t = s] \\ &= \mathbb{E}_{\pi} [R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\ &= \mathbb{E}_{\pi} [R_{t+1} \mid S_t = s] + \gamma \cdot \mathbb{E}_{\pi} [G_{t+1} \mid S_t = s]. \end{aligned}$$

对第一项（即时奖励期望）按策略与状态转移展开：

$$\mathbb{E}_{\pi} [R_{t+1} \mid S_t = s] = \sum_{a \in \mathcal{A}(s)} \pi(a \mid s) \cdot r(s, a).$$

对第二项（未来回报期望），由马尔可夫性可得 $\mathbb{E}_{\pi} [G_{t+1} \mid S_t = s, S_{t+1} = s'] = v_{\pi}(s')$ ，因此：

$$\mathbb{E}_{\pi} [G_{t+1} \mid S_t = s] = \sum_{a \in \mathcal{A}(s)} \pi(a \mid s) \sum_{s' \in \mathcal{S}} p(s' \mid s, a) \cdot v_{\pi}(s').$$

合并两项后得到贝尔曼期望方程：

核心定理

贝尔曼期望方程（Bellman Expectation Equation）

$$v_{\pi}(s) = \sum_{a \in \mathcal{A}(s)} \pi(a \mid s) \left(r(s, a) + \gamma \sum_{s' \in \mathcal{S}} p(s' \mid s, a) v_{\pi}(s') \right), \quad \forall s \in \mathcal{S}. \quad (1)$$

直观含义：当前状态的价值 = 即时奖励的期望 + 折扣后所有后续状态价值的加权期望。

3. 矩阵向量形式

对于有限离散状态空间，可将贝尔曼方程写为紧凑的矩阵形式。定义：

- 状态价值向量 $\mathbf{v}_{\pi} = [v_{\pi}(s_1), v_{\pi}(s_2), \dots, v_{\pi}(s_n)]^T \in \mathbb{R}^n$ ；
- 策略即时奖励向量 $\mathbf{r}_{\pi} = [r_{\pi}(s_1), r_{\pi}(s_2), \dots, r_{\pi}(s_n)]^T \in \mathbb{R}^n$ ，其中 $r_{\pi}(s) = \sum_a \pi(a \mid s) r(s, a)$ ；
- 策略状态转移矩阵 $\mathbf{P}_{\pi} \in \mathbb{R}^{n \times n}$ ，元素 $(\mathbf{P}_{\pi})_{i,j} = \sum_a \pi(a \mid s_i) p(s_j \mid s_i, a)$ 。

则贝尔曼方程的矩阵形式为：

$$\mathbf{v}_{\pi} = \mathbf{r}_{\pi} + \gamma \mathbf{P}_{\pi} \mathbf{v}_{\pi}. \quad (2)$$

4. 策略评估：贝尔曼方程的求解

策略评估（Policy Evaluation）即给定固定策略 π ，求解贝尔曼方程以得到对应状态价值函数 v_π 。

解法 1：解析闭式解

对矩阵形式直接代数整理求解：

$$\mathbf{v}_\pi = (\mathbf{I} - \gamma \mathbf{P}_\pi)^{-1} \mathbf{r}_\pi,$$

其中 $\mathbf{I}$ 为 n 阶单位矩阵。该方法仅适用于小规模状态空间，实际场景中状态数量巨大时，矩阵求逆计算复杂度极高、不可行。

解法 2：迭代法（含收敛性证明）

通过迭代更新逐步逼近真实价值函数，迭代公式为：

$$\mathbf{v}_{k+1} = \mathbf{r}_\pi + \gamma \mathbf{P}_\pi \mathbf{v}_k.$$

- 初始值：可任意初始化 $\mathbf{v}_0$ ；
- 收敛性：当迭代步数 $k \rightarrow \infty$ 时， $\mathbf{v}_k \rightarrow \mathbf{v}_\pi$ 。

证明

迭代法收敛性证明（压缩映射原理）

设 $\mathbf{v}_\pi$ 为方程 (2) 的唯一解（即真值），定义第 k 步的误差向量 $\boldsymbol{\delta}_k = \mathbf{v}_k - \mathbf{v}_\pi$ 。

由迭代公式与不动点方程相减，可得误差的递推关系：

$$\boldsymbol{\delta}_{k+1} = \mathbf{v}_{k+1} - \mathbf{v}_\pi = (\mathbf{r}_\pi + \gamma \mathbf{P}_\pi \mathbf{v}_k) - (\mathbf{r}_\pi + \gamma \mathbf{P}_\pi \mathbf{v}_\pi) = \gamma \mathbf{P}_\pi \boldsymbol{\delta}_k.$$

对上式两边同时取无穷范数（ ℓ_∞ 范数），并结合范数的相容性（次乘法性）：

$$\|\boldsymbol{\delta}_{k+1}\|_\infty = \|\gamma \mathbf{P}_\pi \boldsymbol{\delta}_k\|_\infty \leq \gamma \cdot \|\mathbf{P}_\pi\|_\infty \cdot \|\boldsymbol{\delta}_k\|_\infty.$$

由于 $\mathbf{P}_\pi$ 是行随机矩阵（每行元素非负且和为 1），其诱导的无穷范数（即最大行和）为：

$$\|\mathbf{P}_\pi\|_\infty = \max_i \sum_j |(\mathbf{P}_\pi)_{i,j}| = 1.$$

结合折扣因子 $\gamma \in [0, 1)$ ，可得误差范数的递推不等式：

$$\|\boldsymbol{\delta}_{k+1}\|_\infty \leq \gamma \|\boldsymbol{\delta}_k\|_\infty.$$

递推展开至初始步：

$$\|\boldsymbol{\delta}_k\|_\infty \leq \gamma^k \|\boldsymbol{\delta}_0\|_\infty.$$

因为 $0 \leq \gamma < 1$ ，所以当 $k \rightarrow \infty$ 时， $\gamma^k \rightarrow 0$ ，从而有：

$$\lim_{k \rightarrow \infty} \|\boldsymbol{\delta}_k\|_\infty = 0.$$

这意味着向量序列 $\{\mathbf{v}_k\}$ 在范数意义下收敛于 $\mathbf{v}_\pi$ ，即：

$$\lim_{k \rightarrow \infty} \mathbf{v}_k = \mathbf{v}_\pi.$$

证毕。

□

备注

上述证明本质是**压缩映射 (Banach 不动点) 定理**在有限维向量空间的具体应用。算子 $\mathcal{T}_\pi(\mathbf{v}) = \mathbf{r}_\pi + \gamma \mathbf{P}_\pi \mathbf{v}$ 是一个 γ -收缩映射，保证了迭代的线性收敛速度，收敛速率由 γ 决定 (γ 越接近 0，收敛越快)。

5. 动作价值函数

动作价值函数定义为：在状态 s 下执行动作 a ，之后始终遵循策略 π 交互所能获得的期望折扣回报：

$$q_\pi(s, a) = \mathbb{E}_\pi [G_t \mid S_t = s, A_t = a].$$

展开后的递归形式为：

$$q_\pi(s, a) = r(s, a) + \gamma \sum_{s' \in \mathcal{S}} p(s' \mid s, a) v_\pi(s').$$

状态价值函数与动作价值函数满足如下关系：

$$v_\pi(s) = \sum_{a \in \mathcal{A}(s)} \pi(a \mid s) q_\pi(s, a).$$