

第 3 讲：最优状态价值与贝尔曼最优方程

第 3 讲：最优状态价值与贝尔曼最优方程

强化学习的最终目标是寻找最优策略，因此需要明确最优策略的严格定义。本章包含一个核心概念与一个核心工具：核心概念是**最优状态价值**，基于它可以定义最优策略；核心工具是**贝尔曼最优方程**（Bellman Optimality Equation, BOE），通过求解该方程可以得到最优状态价值与最优策略。

本章与前后章节的关联如下：第 2 讲介绍了任意给定策略对应的贝尔曼方程，本章介绍的贝尔曼最优方程是一类特殊的贝尔曼方程，其对应的策略为最优策略；第 4 讲将介绍的值迭代算法，正是求解贝尔曼最优方程的数值算法。

3.1 动机示例：如何改进策略

我们通过一个简单的网格世界示例说明策略改进的基本思想。示例中橙色格子为禁区，蓝色格子为目标区域。给定一个初始策略，它在状态 s_1 选择向右的动作 a_2 ，这并非最优选择。

直觉层面：在状态 s_1 选择向下的动作 a_3 可以避免进入禁区，从而获得更高的长期回报，策略因此得到改进。

数学层面：上述直觉可以通过计算状态价值与动作价值严格验证。

首先计算给定策略 π 下的状态价值，该策略对应的贝尔曼方程为：

$$\begin{cases} v_{\pi}(s_1) = -1 + \gamma v_{\pi}(s_2) \\ v_{\pi}(s_2) = 1 + \gamma v_{\pi}(s_4) \\ v_{\pi}(s_3) = 1 + \gamma v_{\pi}(s_4) \\ v_{\pi}(s_4) = 1 + \gamma v_{\pi}(s_4) \end{cases}$$

取折扣因子 $\gamma = 0.9$ ，可解得：

$$v_{\pi}(s_4) = v_{\pi}(s_3) = v_{\pi}(s_2) = 10, \quad v_{\pi}(s_1) = 8$$

接下来计算状态 s_1 下所有动作对应的动作价值：

$$\begin{aligned} q_{\pi}(s_1, a_1) &= -1 + \gamma v_{\pi}(s_1) = 6.2 \\ q_{\pi}(s_1, a_2) &= -1 + \gamma v_{\pi}(s_2) = 8 \\ q_{\pi}(s_1, a_3) &= 0 + \gamma v_{\pi}(s_3) = 9 \\ q_{\pi}(s_1, a_4) &= -1 + \gamma v_{\pi}(s_1) = 6.2 \\ q_{\pi}(s_1, a_5) &= 0 + \gamma v_{\pi}(s_1) = 7.2 \end{aligned}$$

可以看到动作 a_3 对应的动作价值最大，满足：

$$q_{\pi}(s_1, a_3) \geq q_{\pi}(s_1, a_i), \quad \forall i \neq 3$$

因此，将策略更新为在 s_1 处选择动作 a_3 ，即可得到更优的策略。

该示例揭示了策略改进的基本思想：将策略更新为选择动作价值最大的动作，即可得到更优的策略。这也是绝大多数强化学习算法的核心思路。

3.2 最优状态价值与最优策略

强化学习的最终目标是获得最优策略，而最优策略的定义基于状态价值。对于两个策略 π_1 和 π_2 ，若对任意状态 $s \in \mathcal{S}$ ，都有 $v_{\pi_1}(s) \geq v_{\pi_2}(s)$ ，则称策略 π_1 优于 π_2 。进一步地，若一个策略优于所有其他可能的策略，则称其为最优策略。

定义

最优策略与最优状态价值：若策略 π^* 满足对任意状态 $s \in \mathcal{S}$ 以及任意其他策略 π ，都有

$$v_{\pi^*}(s) \geq v_{\pi}(s)$$

则称 π^* 为**最优策略**，其对应的状态价值 v_{π^*} 称为**最优状态价值**，记为 v^* 。

基于该定义，自然引出一系列基础问题：- 存在性：最优策略是否一定存在？- 唯一性：最优策略是否唯一？- 随机性：最优策略是随机策略还是确定性策略？- 算法：如何求解最优策略与最优状态价值？

本章后续内容将逐一解答这些问题。

3.3 贝尔曼最优方程

分析最优策略与最优状态价值的核心工具是贝尔曼最优方程（BOE），求解该方程即可得到最优策略与最优状态价值。

对任意状态 $s \in \mathcal{S}$ ，贝尔曼最优方程的元素形式为：

$$\begin{aligned} v(s) &= \max_{\pi(s) \in \Pi(s)} \sum_{a \in \mathcal{A}} \pi(a | s) \left(\sum_{r \in \mathcal{R}} p(r | s, a) r + \gamma \sum_{s' \in \mathcal{S}} p(s' | s, a) v(s') \right) \\ &= \max_{\pi(s) \in \Pi(s)} \sum_{a \in \mathcal{A}} \pi(a | s) q(s, a) \end{aligned} \quad (1)$$

其中 $v(s), v(s')$ 是待求解的未知变量，动作价值函数定义为：

$$q(s, a) \doteq \sum_{r \in \mathcal{R}} p(r | s, a) r + \gamma \sum_{s' \in \mathcal{S}} p(s' | s, a) v(s')$$

式中 $\pi(s)$ 表示状态 s 处的策略， $\Pi(s)$ 表示状态 s 处所有可能策略构成的集合。

贝尔曼最优方程是一个非线性方程，围绕它需要解答以下核心问题：解的存在性、解的唯一性、求解算法、解与最优策略的对应关系。

3.3.1 方程右端的最大化问题

贝尔曼最优方程看似包含 $v(s)$ 和 $\pi(a | s)$ 两个未知变量，但二者可以分步求解：先固定 $v(s)$ ，求解右端最大化问题得到最优策略；再代入方程求解最优价值。

我们通过一个简单例子理解该思路：给定 $q_1, q_2, q_3 \in \mathbb{R}$ ，寻找非负系数 c_1, c_2, c_3 满足 $c_1 + c_2 + c_3 = 1$ ，使得 $\sum_{i=1}^3 c_i q_i$ 最大。不妨设 $q_3 \geq q_1, q_2$ ，则最优解为 $c_3^* = 1, c_1^* = c_2^* = 0$ 。

将该结论推广到策略最大化问题：由于 $\sum_{a \in \mathcal{A}} \pi(a | s) = 1$ 且 $\pi(a | s) \geq 0$ ，加权和 $\sum_{a \in \mathcal{A}} \pi(a | s)q(s, a)$ 的最大值等于最大的动作价值，即

$$\max_{\pi(s)} \sum_{a \in \mathcal{A}} \pi(a | s)q(s, a) = \max_{a \in \mathcal{A}} q(s, a)$$

等号成立当且仅当策略将全部概率赋予动作价值最大的动作：

$$\pi(a | s) = \begin{cases} 1, & a = a^* \\ 0, & a \neq a^* \end{cases}$$

其中 $a^* = \arg \max_a q(s, a)$ 。

由此得到重要结论：**最优策略是确定性的贪心策略，在每个状态选择动作价值最大的动作。**

3.3.2 矩阵-向量形式

贝尔曼最优方程是定义在所有状态上的方程组，可整理为紧凑的矩阵-向量形式：

$$\mathbf{v} = \max_{\pi \in \Pi} (\mathbf{r}_\pi + \gamma \mathbf{P}_\pi \mathbf{v}) \quad (2)$$

其中 $\mathbf{v} \in \mathbb{R}^{|S|}$ 为状态价值向量， $\max_{\pi}$ 表示按元素逐个取最大值。 $\mathbf{r}_\pi$ 和 $\mathbf{P}_\pi$ 与普通贝尔曼方程中的定义一致：- $[\mathbf{r}_\pi]_s = \sum_{a \in \mathcal{A}} \pi(a | s) \sum_{r \in \mathcal{R}} p(r | s, a)r$ - $[\mathbf{P}_\pi]_{s, s'} = \sum_{a \in \mathcal{A}} \pi(a | s) p(s' | s, a)$

由于最优策略由价值 $\mathbf{v}$ 决定，方程右端是关于 $\mathbf{v}$ 的函数，记为

$$f(\mathbf{v}) \doteq \max_{\pi \in \Pi} (\mathbf{r}_\pi + \gamma \mathbf{P}_\pi \mathbf{v})$$

于是贝尔曼最优方程可简写为不动点形式：

$$\mathbf{v} = f(\mathbf{v}) \quad (3)$$

3.3.3 压缩映射定理

贝尔曼最优方程是形如 $\mathbf{v} = f(\mathbf{v})$ 的非线性不动点方程，分析这类方程的核心工具是**压缩映射定理**（又称不动点定理）。

定理 3.1 压缩映射定理

对于方程 $x = f(x)$ （ x 与 $f(x)$ 为实向量），若映射 f 是压缩映射，即存在 $\gamma \in (0, 1)$ ，使得对任意 x_1, x_2 都有

$$\|f(x_1) - f(x_2)\| \leq \gamma \|x_1 - x_2\|$$

则以下三条性质成立：

1. **存在性**：存在不动点 x^* 满足 $f(x^*) = x^*$ 。
2. **唯一性**：不动点 x^* 是唯一的。
3. **迭代收敛性**：迭代过程 $x_{k+1} = f(x_k)$ （ $k = 0, 1, 2, \dots$ ）对任意初始值 x_0 都收敛到 x^* ，且收敛速度为指数级。

压缩映射定理不仅保证了解的存在性与唯一性，还给出了数值求解算法——迭代法。

证明

我们通过柯西序列的性质分四步证明该定理。

第一步：证明迭代序列 $\{x_k\}_{k=1}^{\infty}$ 是柯西序列

由压缩映射性质，相邻迭代项满足：

$$\|x_{k+1} - x_k\| = \|f(x_k) - f(x_{k-1})\| \leq \gamma \|x_k - x_{k-1}\|$$

递推可得：

$$\|x_{k+1} - x_k\| \leq \gamma^k \|x_1 - x_0\|$$

对任意 $m > n$ ，由三角不等式：

$$\begin{aligned}\|x_m - x_n\| &\leq \sum_{k=n}^{m-1} \|x_{k+1} - x_k\| \\ &\leq \sum_{k=n}^{m-1} \gamma^k \|x_1 - x_0\| \\ &\leq \gamma^n \sum_{k=0}^{\infty} \gamma^k \|x_1 - x_0\| \\ &= \frac{\gamma^n}{1 - \gamma} \|x_1 - x_0\|\end{aligned}$$

由于 $\gamma < 1$ ，当 $n \rightarrow \infty$ 时右端趋于 0，因此 $\{x_k\}$ 是柯西序列，必定收敛到某个极限 $x^* = \lim_{k \rightarrow \infty} x_k$ 。

第二步：证明极限 x^* 是不动点

由 $\|x_{k+1} - x_k\| \leq \gamma^k \|x_1 - x_0\|$ ，当 $k \rightarrow \infty$ 时 $\|f(x_k) - x_k\| \rightarrow 0$ ，因此在极限处有 $f(x^*) = x^*$ ，即 x^* 是不动点。

第三步：证明不动点唯一

假设存在两个不动点 x^* 和 x' ，满足 $f(x^*) = x^*$ 且 $f(x') = x'$ 。则：

$$\|x' - x^*\| = \|f(x') - f(x^*)\| \leq \gamma \|x' - x^*\|$$

由于 $\gamma < 1$ ，该不等式成立当且仅当 $\|x' - x^*\| = 0$ ，即 $x' = x^*$ ，故不动点唯一。

第四步：证明指数级收敛速度

由第一步的结论，令 $m \rightarrow \infty$ 可得：

$$\|x^* - x_n\| \leq \frac{\gamma^n}{1 - \gamma} \|x_1 - x_0\|$$

误差随迭代步数 n 指数衰减，因此收敛速度为指数级。

3.3.4 贝尔曼最优方程右端的压缩性质

要将压缩映射定理应用于贝尔曼最优方程，需要证明 $f(v)$ 是压缩映射。

定理 3.2 $f(v)$ 的压缩性质

贝尔曼最优方程右端的映射 $f(v) = \max_{\pi \in \Pi} (r_{\pi} + \gamma P_{\pi} v)$ 是无穷范数下的压缩映射，即对任意 $v_1, v_2 \in \mathbb{R}^{|S|}$ ，都有

$$\|f(v_1) - f(v_2)\|_{\infty} \leq \gamma \|v_1 - v_2\|_{\infty}$$

其中 $\gamma \in (0, 1)$ 为折扣因子， $\|\cdot\|_{\infty}$ 为向量的无穷范数（最大绝对值范数）。

证明

设 $\pi_1^* = \arg \max_{\pi} (r_{\pi} + \gamma P_{\pi} v_1)$ ， $\pi_2^* = \arg \max_{\pi} (r_{\pi} + \gamma P_{\pi} v_2)$ ，则由最大值的定义有：

$$f(v_1) = r_{\pi_1^*} + \gamma P_{\pi_1^*} v_1 \geq r_{\pi_2^*} + \gamma P_{\pi_2^*} v_1$$

$$f(v_2) = r_{\pi_2^*} + \gamma P_{\pi_2^*} v_2 \geq r_{\pi_1^*} + \gamma P_{\pi_1^*} v_2$$

上述比较均为按元素比较。

对 $f(v_1) - f(v_2)$ 做放缩：

$$\begin{aligned} f(v_1) - f(v_2) &= r_{\pi_1^*} + \gamma P_{\pi_1^*} v_1 - (r_{\pi_2^*} + \gamma P_{\pi_2^*} v_2) \\ &\leq r_{\pi_1^*} + \gamma P_{\pi_1^*} v_1 - (r_{\pi_1^*} + \gamma P_{\pi_1^*} v_2) \\ &= \gamma P_{\pi_1^*} (v_1 - v_2) \end{aligned}$$

同理可得：

$$f(v_2) - f(v_1) \leq \gamma P_{\pi_2^*} (v_2 - v_1)$$

因此有双向不等式：

$$-\gamma P_{\pi_2^*} (v_1 - v_2) \leq f(v_1) - f(v_2) \leq \gamma P_{\pi_1^*} (v_1 - v_2)$$

定义向量 z ，其每个元素为对应位置上界与下界的绝对值的最大值，则 $|f(v_1) - f(v_2)| \leq z$ ，因此：

$$\|f(v_1) - f(v_2)\|_{\infty} \leq \|z\|_{\infty}$$

对 z 的第 i 个元素，设 p_i^T 和 q_i^T 分别为 $P_{\pi_1^*}$ 和 $P_{\pi_2^*}$ 的第 i 行，则：

$$z_i = \max \{ \gamma |p_i^T (v_1 - v_2)|, \gamma |q_i^T (v_1 - v_2)| \}$$

由于状态转移矩阵的行和为 1 且元素非负，因此：

$$|p_i^T (v_1 - v_2)| \leq p_i^T |v_1 - v_2| \leq \|v_1 - v_2\|_{\infty}$$

同理 $|q_i^T (v_1 - v_2)| \leq \|v_1 - v_2\|_{\infty}$ 。

因此 $z_i \leq \gamma \|v_1 - v_2\|_{\infty}$ ，对所有 i 取最大值得：

$$\|z\|_{\infty} \leq \gamma \|v_1 - v_2\|_{\infty}$$

联立可得 $\|f(v_1) - f(v_2)\|_{\infty} \leq \gamma \|v_1 - v_2\|_{\infty}$ ，压缩性质得证。

3.4 从贝尔曼最优方程求解最优策略

基于压缩映射定理，我们可以严格分析贝尔曼最优方程的解，并得到最优状态价值与最优策略。

求解最优状态价值 v^*

若 v^* 是贝尔曼最优方程的解，则满足：

$$v^* = \max_{\pi \in \Pi} (r_\pi + \gamma P_\pi v^*)$$

即 v^* 是映射 f 的不动点。结合压缩映射定理，可得到如下核心结论。

定理 3.3 解的存在性、唯一性与迭代算法

对于贝尔曼最优方程 $v = f(v) = \max_{\pi \in \Pi} (r_\pi + \gamma P_\pi v)$ ：

1. 存在唯一的解 v^* ，即最优状态价值；
2. 可通过迭代算法求解：

$$v_{k+1} = f(v_k) = \max_{\pi \in \Pi} (r_\pi + \gamma P_\pi v_k), \quad k = 0, 1, 2, \dots$$

对任意初始值 v_0 ，迭代序列 v_k 都将以指数速度收敛到 v^* 。

该迭代算法就是第 4 讲将详细介绍的**值迭代算法**。

求解最优策略 π^*

得到最优状态价值 v^* 后，最优策略可通过下式求解：

$$\pi^* = \arg \max_{\pi \in \Pi} (r_\pi + \gamma P_\pi v^*)$$

将 π^* 代入贝尔曼最优方程可得：

$$v^* = r_{\pi^*} + \gamma P_{\pi^*} v^*$$

这说明 $v^* = v_{\pi^*}$ ，即最优状态价值正是最优策略对应的状态价值，贝尔曼最优方程是对应最优策略的特殊贝尔曼方程。

接下来的定理保证了上述解的最优性。

定理 3.4 v^* 与 π^* 的最优性

贝尔曼最优方程的解 v^* 是最优状态价值，对应的 π^* 是最优策略。即对任意策略 π ，都有

$$v^* = v_{\pi^*} \geq v_\pi$$

其中不等号为按元素比较。

证明

对任意策略 π ，其状态价值满足贝尔曼方程：

$$v_\pi = r_\pi + \gamma P_\pi v_\pi$$

由 v^* 的定义，有：

$$v^* = \max_{\pi} (r_\pi + \gamma P_\pi v^*) = r_{\pi^*} + \gamma P_{\pi^*} v^* \geq r_\pi + \gamma P_\pi v^*$$

两式相减得：

$$v^* - v_\pi \geq (r_\pi + \gamma P_\pi v^*) - (r_\pi + \gamma P_\pi v_\pi) = \gamma P_\pi (v^* - v_\pi)$$

反复应用该不等式递推可得：

$$\mathbf{v}^* - \mathbf{v}_\pi \geq \gamma^n \mathbf{P}_\pi^n (\mathbf{v}^* - \mathbf{v}_\pi)$$

当 $n \rightarrow \infty$ 时，由于 $\gamma < 1$ 且 $\mathbf{P}_\pi^n$ 是行和为 1 的非负矩阵，右端趋于零向量，因此：

$$\mathbf{v}^* - \mathbf{v}_\pi \geq 0$$

即对任意策略 π 都有 $v^* \geq v_\pi$ ，最优性得证。

贪心最优策略

进一步地，我们可以证明存在确定性的贪心最优策略。

定理 3.5 贪心最优策略

对任意状态 $s \in \mathcal{S}$ ，如下确定性贪心策略是最优策略：

$$\pi^*(a | s) = \begin{cases} 1, & a = a^*(s) \\ 0, & a \neq a^*(s) \end{cases} \quad (4)$$

其中 $a^*(s) = \arg \max_a q_*(s, a)$ ，最优动作价值定义为：

$$q_*(s, a) \doteq \sum_{r \in \mathcal{R}} p(r | s, a) r + \gamma \sum_{s' \in \mathcal{S}} p(s' | s, a) v_*(s')$$

证明

最优策略的元素形式为：

$$\pi^*(s) = \arg \max_{\pi \in \Pi(s)} \sum_{a \in \mathcal{A}} \pi(a | s) q_*(s, a)$$

由 3.3.1 节的结论，加权和 $\sum_a \pi(a | s) q_*(s, a)$ 在策略将全部概率赋予最大动作价值的动作时取得最大值，因此上述贪心策略是最优策略。

关于最优策略，有两点重要性质：
- **唯一性**：最优状态价值 v^* 是唯一的，但对应的最优策略不一定唯一，可能存在多个策略达到相同的最优状态价值。
- **随机性**：最优策略可以是随机的也可以是确定性的，但一定存在确定性的贪心最优策略。

3.5 影响最优策略的因素

通过贝尔曼最优方程可以分析影响最优策略的因素。从方程形式可以看出，最优状态价值与最优策略由三个要素决定：即时奖励 r 、折扣因子 γ 、环境模型 $p(s' | s, a)$ 和 $p(r | s, a)$ 。

折扣因子的影响

折扣因子 γ 决定了智能体的“远见程度”：
- 当 γ 较大时（如 $\gamma = 0.9$ ），智能体更看重长期回报，愿意承担短期风险以获取更高的长期收益，甚至愿意穿过禁区到达目标区域。
- 当 γ 较小时（如 $\gamma = 0.5$ ），智能体变得短视，会规避短期风险，选择更保守的路径绕开禁区。
- 当 $\gamma = 0$ 时，智能体完全只看即时奖励，无法规划到达目标的路径。

此外，状态价值的空间分布呈现出“离目标越近价值越高”的规律，这正是折扣因子作用的体现：路径越长，未来奖励的折扣衰减越严重。

奖励值的影响

调整奖励值可以改变智能体的行为偏好。例如增大禁区的惩罚（如从-1 改为-10），最优策略将主动避开所有禁区。

但奖励值的调整并非都会改变最优策略，最优策略对奖励的仿射变换具有不变性。

定理 3.6 最优策略不变性

设原 MDP 的最优状态价值为 v^* ，满足 $v^* = \max_{\pi}(\mathbf{r}_{\pi} + \gamma \mathbf{P}_{\pi} v^*)$ 。若将所有奖励做仿射变换 $r \rightarrow \alpha r + \beta$ （其中 $\alpha > 0$, $\alpha, \beta \in \mathbb{R}$ ），则新的最优状态价值为：

$$v' = \alpha v^* + \frac{\beta}{1 - \gamma} \mathbf{1} \quad (5)$$

其中 $\mathbf{1}$ 为全 1 向量。由此得到的最优策略与原最优策略完全相同，即最优策略在奖励的仿射变换下保持不变。

证明

奖励做仿射变换后，策略的即时奖励向量变为 $\mathbf{r}'_{\pi} = \alpha \mathbf{r}_{\pi} + \beta \mathbf{1}$ ，新的贝尔曼最优方程为：

$$v' = \max_{\pi \in \Pi} (\alpha \mathbf{r}_{\pi} + \beta \mathbf{1} + \gamma \mathbf{P}_{\pi} v')$$

我们猜测解的形式为 $v' = \alpha v^* + c \mathbf{1}$ ，其中 $c = \beta / (1 - \gamma)$ ，代入方程右端：

$$\begin{aligned} \max_{\pi} (\alpha \mathbf{r}_{\pi} + \beta \mathbf{1} + \gamma \mathbf{P}_{\pi} (\alpha v^* + c \mathbf{1})) &= \max_{\pi} (\alpha \mathbf{r}_{\pi} + \beta \mathbf{1} + \alpha \gamma \mathbf{P}_{\pi} v^* + c \gamma \mathbf{1}) \\ &= \alpha \max_{\pi} (\mathbf{r}_{\pi} + \gamma \mathbf{P}_{\pi} v^*) + (\beta + c \gamma) \mathbf{1} \end{aligned}$$

其中利用了 $\mathbf{P}_{\pi} \mathbf{1} = \mathbf{1}$ 的性质。

由于 $v^* = \max_{\pi}(\mathbf{r}_{\pi} + \gamma \mathbf{P}_{\pi} v^*)$ ，代入得：

$$\text{右端} = \alpha v^* + (\beta + c \gamma) \mathbf{1}$$

令其等于左端 $\alpha v^* + c \mathbf{1}$ ，解得 $c = \beta + c \gamma$ ，即 $c = \beta / (1 - \gamma)$ ，与假设一致。

因此 $v' = \alpha v^* + \frac{\beta}{1 - \gamma} \mathbf{1}$ 是新方程的解。由于解唯一，这就是新的最优状态价值。

由于仿射变换不改变动作价值之间的相对大小关系，因此贪心最优策略保持不变。

避免无意义绕路

一个常见的疑问是：如果每步移动的即时奖励为 0，最优策略是否会在到达目标前无意义地绕路？

答案是否定的。即使每步即时奖励为 0，折扣因子也会自动促使智能体尽快到达目标：绕路会增加轨迹长度，导致未来目标奖励的折扣衰减更严重，从而降低总回报。因此，更短的轨迹对应更高的折扣回报，最优策略不会选择无意义的绕路。

备注

为每步移动增加负奖励以促使智能体走最短路径，本质上是对奖励做仿射变换，并不会改变最优策略。折扣因子本身已经隐含了“尽快到达目标”的激励。

3.6 本章小结

本章的核心概念是最优策略与最优状态价值：若一个策略在所有状态上的状态价值都不低于其他任何策略，则称其为最优策略，对应的状态价值为最优状态价值。

本章的核心工具是贝尔曼最优方程，它是一个具有压缩性质的非线性不动点方程。通过压缩映射定理可以证明：该方程存在唯一的最优状态价值解，且可通过迭代算法指数收敛到该解；对应的贪心策略即为最优策略。

本章的结论是后续值迭代、策略迭代等核心算法的理论基础。

3.7 常见问题解答

• **Q：最优策略的定义是什么？**

A：若一个策略对应的状态价值在所有状态上都大于等于其他任意策略，则该策略为最优策略。该定义适用于表格型强化学习，函数近似场景下需要采用其他评价标准。

• **Q：贝尔曼最优方程为什么重要？**

A：它同时刻画了最优策略与最优状态价值，求解该方程即可得到最优策略与对应的最优状态价值。

• **Q：贝尔曼最优方程属于贝尔曼方程吗？**

A：是的。贝尔曼最优方程是一类特殊的贝尔曼方程，其对应的策略为最优策略。

• **Q：贝尔曼最优方程的解是唯一的吗？**

A：最优状态价值的解是唯一的，但对应的最优策略不一定唯一，可能存在多个策略达到相同的最优状态价值。

• **Q：分析贝尔曼最优方程解的关键性质是什么？**

A：方程右端的映射是压缩映射，因此可以应用压缩映射定理分析解的存在性、唯一性与收敛性。

• **Q：最优策略一定存在吗？**

A：是的，基于贝尔曼最优方程的分析，最优策略总是存在的。

• **Q：最优策略是随机的还是确定性的？**

A：最优策略既可以是随机的也可以是确定性的，但一定存在确定性的贪心最优策略。

• **Q：如何得到最优策略？**

A：通过迭代算法求解贝尔曼最优方程，得到最优状态价值后，取贪心策略即可得到最优策略。后续章节介绍各类强化学习算法，本质上都是不同设定下求解最优策略。

• **Q：减小折扣因子对最优策略有什么影响？**

A：折扣因子减小会使最优策略变得更短视，智能体不愿承担短期风险，即使长期收益更高。

• **Q：折扣因子设为 0 会怎样？**

A：此时智能体完全只关注即时奖励，会选择当前即时奖励最大的动作，不考虑长期后果。

• **Q：所有奖励同时增加相同数值，最优状态价值和最优策略会变化吗？**

A：最优状态价值会增加（满足仿射变换公式），但最优策略保持不变。因为这是奖励的仿射变换，不改变动作价值的相对大小。

• **Q：为了让智能体不绕路，需要给每步加负奖励吗？**

A：不需要。首先，给所有步骤加相同负奖励是仿射变换，不改变最优策略；其次，折扣因子本身会激励智能体尽快到达目标，绕路会降低折扣回报。