

第 9 讲：策略梯度方法

第 9 讲：策略梯度方法

函数近似的思想不仅可以用于表示状态/动作价值（如第 8 讲所述），还可以用于表示策略，这正是本章的核心主题。到目前为止，本书中的策略一直以表格形式表示：所有状态的动作概率都存储在一张表中。本章将展示，策略可以用参数化函数来表示，记作 $\pi(a|s, \theta)$ ，其中 $\theta \in \mathbb{R}^m$ 是参数向量。该形式也可以写作 $\pi_\theta(a|s)$ 、 $\pi_\theta(a, s)$ 或 $\pi(a, s; \theta)$ 。

当策略以函数形式表示时，可以通过优化某个标量指标来获得最优策略。这种方法被称为**策略梯度**（policy gradient）。策略梯度方法是本书的一大进步，因为它是**基于策略的**（policy-based）方法，而此前各章讨论的都是**基于价值的**（value-based）方法。策略梯度方法的优势众多。例如，它在处理大状态/动作空间时效率更高；它具有更强的泛化能力，因此样本利用效率更高。

9.1 策略表示：从表格到函数

当策略的表示从表格切换到函数时，有必要澄清两种表示方法的区别。

- **第一，如何定义最优策略？**当用表格表示时，若一个策略能最大化每个状态的价值，则该策略被定义为最优。当用函数表示时，若一个策略能最大化某个**标量指标**，则该策略被定义为最优。
- **第二，如何更新策略？**当用表格表示时，可以通过直接修改表中条目来更新策略。当用参数化函数表示时，策略无法再通过这种方式更新，只能通过改变参数 θ 来更新。
- **第三，如何获取动作的概率？**在表格情况下，可以直接查表获取动作的概率。在函数表示情况下，需要将 (s, a) 输入函数计算其概率。根据函数的结构不同，也可以输入状态然后输出所有动作的概率。

策略梯度方法的基本思想总结如下。设 $J(\theta)$ 是一个标量指标，可以通过基于梯度的算法优化该指标来获得最优策略：

$$\theta_{t+1} = \theta_t + \alpha \nabla_{\theta} J(\theta_t);$$

其中 $\nabla_{\theta} J$ 是 J 对 θ 的梯度， t 是时间步， α 是优化步长。

基于这一基本思想，本章将回答以下三个问题：

- 应该使用什么指标？（第 9.2 节）
- 如何计算这些指标的梯度？（第 9.3 节）
- 如何利用经验样本计算梯度？（第 9.4 节）

9.2 定义最优策略的指标

如果策略用函数表示，有两种类型的指标可用于定义最优策略。一种基于状态价值，另一种基于即时奖励。

指标 1: 平均状态价值

第一个指标是**平均状态价值** (average state value), 简称平均价值。其定义为:

$$\bar{v}_\pi = \sum_{s \in \mathcal{S}} d(s) v_\pi(s);$$

其中 $d(s)$ 是状态 s 的权重。它满足对任意 $s \in \mathcal{S}$ 有 $d(s) \geq 0$, 且 $\sum_{s \in \mathcal{S}} d(s) = 1$ 。因此, 可以将 $d(s)$ 解释为 s 的概率分布。那么该指标可以写作:

$$\bar{v}_\pi = \mathbb{E}_{S \sim d}[v_\pi(S)].$$

如何选择分布 d ? 这是一个重要问题, 有两种情形。

- 第一种也是最简单的情形是 d 独立于策略 π 。此时我们特别记 d 为 d_0 , 记 $\bar{v}_\pi$ 为 $\bar{v}_\pi^0$ 以表明该分布与策略无关。一种情况是将所有状态视为同等重要并取 $d_0(s) = 1/|\mathcal{S}|$ 。另一种情况是我们只关心某个特定状态 s_0 (如智能体总是从 s_0 出发), 此时可以设计 $d_0(s_0) = 1$, $d_0(s \neq s_0) = 0$ 。
- 第二种情形是 d 依赖于策略 π 。此时通常取 d 为 π 下的**平稳分布** d_π 。 d_π 的一个基本性质是它满足:

$$d_\pi^T \mathbf{P}_\pi = d_\pi^T;$$

其中 $\mathbf{P}_\pi$ 是状态转移概率矩阵。选取 d_π 的解释如下: 平稳分布反映了马尔可夫决策过程在给定策略下的长期行为。如果一个状态在长期中被频繁访问, 它就更重要, 应该得到更高的权重; 如果一个状态很少被访问, 则其重要性较低, 应该得到较低的权重。

顾名思义, $\bar{v}_\pi$ 是状态价值的加权平均。不同的 θ 值会导致不同的 $\bar{v}_\pi$ 值。我们的最终目标是找到一个最优策略 (等价于最优的 θ) 来最大化 $\bar{v}_\pi$ 。

下面介绍 $\bar{v}_\pi$ 的另外两个重要等价表达式。

- 假设智能体遵循给定策略 $\pi(\theta)$ 收集奖励 $\{R_{t+1}\}_{t=0}^\infty$ 。在文献中常见的如下指标:

$$J(\theta) = \lim_{n \rightarrow \infty} \mathbb{E} \left[\sum_{t=0}^n \gamma^t R_{t+1} \right] = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \right]. \quad (1)$$

该指标实际上等于 $\bar{v}_\pi$ 。为了说明这一点:

$$\mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \right] = \sum_{s \in \mathcal{S}} d(s) \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \middle| S_0 = s \right] = \sum_{s \in \mathcal{S}} d(s) v_\pi(s) = \bar{v}_\pi.$$

上式第一个等号是全期望公式, 第二个等号是状态价值的定义。

- 指标 $\bar{v}_\pi$ 还可以改写为两个向量的内积形式。令

$$\mathbf{v}_\pi = [\dots, v_\pi(s), \dots]^T \in \mathbb{R}^{|\mathcal{S}|}, \quad \mathbf{d} = [\dots, d(s), \dots]^T \in \mathbb{R}^{|\mathcal{S}|}.$$

则有:

$$\bar{v}_\pi = \mathbf{d}^T \mathbf{v}_\pi.$$

该表达式在分析其梯度时将非常有用。

指标 2: 平均奖励

第二个指标是**平均单步奖励** (average one-step reward), 简称为平均奖励。其定义为:

$$\bar{r}_\pi := \sum_{s \in \mathcal{S}} d_\pi(s) r_\pi(s) = \mathbb{E}_{S \sim d_\pi}[r_\pi(S)]; \quad (2)$$

其中 d_π 是平稳分布，且

$$r_\pi(s) := \sum_{a \in \mathcal{A}} \pi(a|s, \boldsymbol{\theta}) r(s, a) = \mathbb{E}_{A \sim \pi(s, \boldsymbol{\theta})} [r(s, A) | s] \quad (3)$$

是即时奖励的期望。这里 $r(s, a) := \mathbb{E}[R|s, a] = \sum_r r p(r|s, a)$ 。

下面介绍 $\bar{r}_\pi$ 的另外两个重要等价表达式。

- 假设智能体遵循给定策略 $\pi(\boldsymbol{\theta})$ 收集奖励 $\{R_{t+1}\}_{t=0}^\infty$ 。文献中常见的另一个指标是：

$$J(\boldsymbol{\theta}) = \lim_{n \rightarrow \infty} \frac{1}{n} \mathbb{E} \left[\sum_{t=0}^{n-1} R_{t+1} \right]. \quad (4)$$

它实际上等于 $\bar{r}_\pi$ ：

$$\lim_{n \rightarrow \infty} \frac{1}{n} \mathbb{E} \left[\sum_{t=0}^{n-1} R_{t+1} \right] = \sum_{s \in \mathcal{S}} d_\pi(s) r_\pi(s) = \bar{r}_\pi. \quad (5)$$

(5) 的证明见下文。

- 平均奖励 $\bar{r}_\pi$ 也可以写成两个向量的内积。令

$$\mathbf{r}_\pi = [\dots, r_\pi(s), \dots]^T \in \mathbb{R}^{|\mathcal{S}|}, \quad \mathbf{d}_\pi = [\dots, d_\pi(s), \dots]^T \in \mathbb{R}^{|\mathcal{S}|};$$

其中 $r_\pi(s)$ 由 (3) 定义。则显然有：

$$\bar{r}_\pi = \sum_{s \in \mathcal{S}} d_\pi(s) r_\pi(s) = \mathbf{d}_\pi^T \mathbf{r}_\pi.$$

该表达式在推导其梯度时将非常有用。

证明

证明 (5)：

步骤 1： 首先证明对任意起始状态 $s_0 \in \mathcal{S}$ ，以下等式成立：

$$\bar{r}_\pi = \lim_{n \rightarrow \infty} \frac{1}{n} \mathbb{E} \left[\sum_{t=0}^{n-1} R_{t+1} \mid S_0 = s_0 \right].$$

为此，注意到：

$$\lim_{n \rightarrow \infty} \frac{1}{n} \mathbb{E} \left[\sum_{t=0}^{n-1} R_{t+1} \mid S_0 = s_0 \right] = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{t=0}^{n-1} \mathbb{E}[R_{t+1} | S_0 = s_0] = \lim_{t \rightarrow \infty} \mathbb{E}[R_{t+1} | S_0 = s_0];$$

其中最后一个等号来自 Cesàro 均值的性质：若 $\{a_k\}_{k=1}^\infty$ 是收敛序列且 $\lim_{k \rightarrow \infty} a_k$ 存在，则

$\{\frac{1}{n} \sum_{k=1}^n a_k\}_{n=1}^\infty$ 也是收敛序列且 $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n a_k = \lim_{k \rightarrow \infty} a_k$ 。

进一步考察 $\mathbb{E}[R_{t+1} | S_0 = s_0]$ 。由全期望公式：

$$\mathbb{E}[R_{t+1} | S_0 = s_0] = \sum_{s \in \mathcal{S}} \mathbb{E}[R_{t+1} | S_t = s, S_0 = s_0] p^{(t)}(s | s_0) = \sum_{s \in \mathcal{S}} \mathbb{E}[R_{t+1} | S_t = s] p^{(t)}(s | s_0) = \sum_{s \in \mathcal{S}} r_\pi(s) p^{(t)}(s | s_0);$$

其中 $p^{(t)}(s | s_0)$ 表示从 s_0 出发恰好在 t 步后到达 s 的概率。第三个等号来自马尔可夫记忆无关性质。

由平稳分布的定义， $\lim_{t \rightarrow \infty} p^{(t)}(s | s_0) = d_\pi(s)$ ，因此：

$$\lim_{t \rightarrow \infty} \mathbb{E}[R_{t+1} | S_0 = s_0] = \lim_{t \rightarrow \infty} \sum_{s \in \mathcal{S}} r_\pi(s) p^{(t)}(s | s_0) = \sum_{s \in \mathcal{S}} r_\pi(s) d_\pi(s) = \bar{r}_\pi.$$

步骤 2: 考虑任意状态分布 d 。由全期望公式：

$$\lim_{n \rightarrow \infty} \frac{1}{n} \mathbb{E} \left[\sum_{t=0}^{n-1} R_{t+1} \right] = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{s \in \mathcal{S}} d(s) \mathbb{E} \left[\sum_{t=0}^{n-1} R_{t+1} \mid S_0 = s \right] = \sum_{s \in \mathcal{S}} d(s) \lim_{n \rightarrow \infty} \frac{1}{n} \mathbb{E} \left[\sum_{t=0}^{n-1} R_{t+1} \mid S_0 = s \right].$$

由于步骤 1 对任意起始状态成立，代入得：

$$\lim_{n \rightarrow \infty} \frac{1}{n} \mathbb{E} \left[\sum_{t=0}^{n-1} R_{t+1} \right] = \sum_{s \in \mathcal{S}} d(s) \bar{r}_\pi = \bar{r}_\pi.$$

证明完毕。

备注

到目前为止，我们介绍了两种类型的指标： $\bar{v}_\pi$ 和 $\bar{r}_\pi$ 。每个指标都有几种不同但等价的表达式。有时我们用 $\bar{v}_\pi$ 特指状态分布为平稳分布 d_π 的情形，用 $\bar{v}_\pi^0$ 指 d_0 独立于 π 的情形。

关于这些指标的一些说明：

- 所有这些指标都是 π 的函数。由于 π 由 θ 参数化，这些指标也是 θ 的函数。换句话说，不同的 θ 值可以产生不同的指标值。因此，我们可以搜索 θ 的最优值来最大化这些指标。这就是策略梯度方法的基本思想。
- 在折扣情形 ($\gamma < 1$) 下，两种指标 $\bar{v}_\pi$ 和 $\bar{r}_\pi$ 是等价的。具体而言，可以证明：

$$\bar{r}_\pi = (1 - \gamma) \bar{v}_\pi.$$

上式表明这两个指标可以同时最大化。该等式的证明将在引理 9.1 中给出。

9.3 指标的梯度

给定上一节引入的指标，可以使用基于梯度的方法来最大化它们。为此，需要首先计算这些指标的梯度。本章最重要的理论结果是以下定理。

定理 9.1 策略梯度定理

梯度 $J(\theta)$ ：

$$\nabla_\theta J(\theta) = \sum_{s \in \mathcal{S}} \eta(s) \sum_{a \in \mathcal{A}} \nabla_\theta \pi(a|s, \theta) q_\pi(s, a); \quad (6)$$

其中 η 是一个状态分布， $\nabla_\theta \pi$ 是 π 对 θ 的梯度。此外，(6) 有一个用期望表示的紧凑形式：

$$\nabla_\theta J(\theta) = \mathbb{E}_{S \sim \eta, A \sim \pi(S, \theta)} [\nabla_\theta \ln \pi(A|S, \theta) q_\pi(S, A)]; \quad (7)$$

其中 $\ln$ 是自然对数。

备注

关于定理 9.1 的一些重要说明：

- 需要注意的是，定理 9.1 是定理 9.2、定理 9.3 和定理 9.5 的结果的总结。这三个定理针对不同指标和折扣/非折扣情形的不同场景。这些场景中的梯度都有类似的表达式，因此汇总在定理 9.1 中。 $J(\theta)$ 和 η 的具体表达式未在定理 9.1 中给出，可在定理 9.2、定理 9.3 和定理 9.5 中找到。具体来说， $J(\theta)$ 可以是 $\bar{v}_\pi^0$ 、 $\bar{v}_\pi$ 或 $\bar{r}_\pi$ 。(6) 中的等号可能是精确等式或近似。分布 η 在不同场景中也不同。
- 梯度的推导是策略梯度方法中最复杂的部分。对大多数读者来说，熟悉定理 9.1 的结果而不需要了解证明就足够了。本节后续内容中的推导细节在数学上较为密集，建议读者根据兴趣选择性学习。
- (7) 中的表达式比 (6) 更受欢迎，因为它以期望的形式表达。我们将在第 9.4 节中展示，这个真实梯度可以用随机梯度来近似。

为什么 (6) 可以表示为 (7)? 证明如下。由期望的定义，(6) 可以改写为：

$$\nabla_\theta J(\theta) = \sum_{s \in \mathcal{S}} \eta(s) \sum_{a \in \mathcal{A}} \nabla_\theta \pi(a|s, \theta) q_\pi(s, a) = \mathbb{E}_{S \sim \eta} \left[\sum_{a \in \mathcal{A}} \nabla_\theta \pi(a|S, \theta) q_\pi(S, a) \right].$$

进一步地， $\ln \pi(a|s, \theta)$ 的梯度为：

$$\nabla_\theta \ln \pi(a|s, \theta) = \frac{\nabla_\theta \pi(a|s, \theta)}{\pi(a|s, \theta)}.$$

由此可得：

$$\nabla_\theta \pi(a|s, \theta) = \pi(a|s, \theta) \nabla_\theta \ln \pi(a|s, \theta).$$

代入得：

$$\nabla_\theta J(\theta) = \mathbb{E} \left[\sum_{a \in \mathcal{A}} \pi(a|S, \theta) \nabla_\theta \ln \pi(a|S, \theta) q_\pi(S, a) \right] = \mathbb{E}_{S \sim \eta, A \sim \pi(S, \theta)} [\nabla_\theta \ln \pi(A|S, \theta) q_\pi(S, A)].$$

备注

值得注意的是， $\pi(a|s, \theta)$ 必须对所有 (s, a) 为正，以确保 $\ln \pi(a|s, \theta)$ 有效。这可以通过使用 **softmax** 函数来实现：

$$\pi(a|s, \theta) = \frac{e^{h(s, a, \theta)}}{\sum_{a' \in \mathcal{A}} e^{h(s, a', \theta)}}, \quad a \in \mathcal{A};$$

其中 $h(s, a, \theta)$ 是一个表示在状态 s 选择动作 a 的偏好函数。该策略满足对任意 $s \in \mathcal{S}$ 有 $\pi(a|s, \theta) \in (0, 1)$ 且 $\sum_{a \in \mathcal{A}} \pi(a|s, \theta) = 1$ 。该策略可以用神经网络实现：网络的输入是 s ，输出层是 softmax 层，因此网络输出所有 a 的 $\pi(a|s, \theta)$ 且输出之和为 1。

由于对所有 a 有 $\pi(a|s, \theta) > 0$ ，该策略是**随机性**的，因此具有**探索性**。策略不直接指示采取哪个动作，而是应该根据策略的概率分布来生成动作。

9.3.1 折扣情形下的梯度推导

下面推导在折扣情形 ($\gamma \in (0, 1)$) 下的指标梯度。折扣情形下的状态价值和动作价值定义为：

$$\begin{aligned} v_\pi(s) &= \mathbb{E}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots | S_t = s], \\ q_\pi(s, a) &= \mathbb{E}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots | S_t = s, A_t = a]. \end{aligned}$$

有关系 $v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a|s, \boldsymbol{\theta}) q_\pi(s, a)$ ，状态价值满足贝尔曼方程。

首先，我们说明 $\bar{v}_\pi(\boldsymbol{\theta})$ 和 $\bar{r}_\pi(\boldsymbol{\theta})$ 是等价指标。

定理 9.1 $\bar{v}_\pi(\boldsymbol{\theta})$ 与 $\bar{r}_\pi(\boldsymbol{\theta})$ 的等价性

在折扣情形 ($\gamma \in (0, 1)$) 下，有：

$$\bar{r}_\pi = (1 - \gamma)\bar{v}_\pi.$$

证明

注意 $\bar{v}_\pi(\boldsymbol{\theta}) = \mathbf{d}_\pi^T \mathbf{v}_\pi$ ， $\bar{r}_\pi(\boldsymbol{\theta}) = \mathbf{d}_\pi^T \mathbf{r}_\pi$ ，其中 $\mathbf{v}_\pi$ 和 $\mathbf{r}_\pi$ 满足贝尔曼方程 $\mathbf{v}_\pi = \mathbf{r}_\pi + \gamma \mathbf{P}_\pi \mathbf{v}_\pi$ 。在贝尔曼方程两边同时左乘 $\mathbf{d}_\pi^T$ 得：

$$\bar{v}_\pi = \bar{r}_\pi + \gamma \mathbf{d}_\pi^T \mathbf{P}_\pi \mathbf{v}_\pi = \bar{r}_\pi + \gamma \mathbf{d}_\pi^T \mathbf{v}_\pi = \bar{r}_\pi + \gamma \bar{v}_\pi;$$

由此即得 $\bar{r}_\pi = (1 - \gamma)\bar{v}_\pi$ 。

其次，以下引理给出了对任意 s 的 $v_\pi(s)$ 的梯度。

定理 9.2 $v_\pi(s)$ 的梯度

在折扣情形下，对任意 $s \in \mathcal{S}$ 有：

$$\nabla_{\boldsymbol{\theta}} v_\pi(s) = \sum_{s' \in \mathcal{S}} \Pr_\pi(s'|s) \sum_{a \in \mathcal{A}} \nabla_{\boldsymbol{\theta}} \pi(a|s', \boldsymbol{\theta}) q_\pi(s', a); \quad (8)$$

其中

$$\Pr_\pi(s'|s) := \sum_{k=0}^{\infty} \gamma^k [\mathbf{P}_\pi^k]_{ss'} = [(\mathbf{I}_n - \gamma \mathbf{P}_\pi)^{-1}]_{ss'}$$

是在策略 π 下从 s 转移到 s' 的折扣总概率。这里 $[\cdot]_{ss'}$ 表示第 s 行第 s' 列的条目， $[\mathbf{P}_\pi^k]_{ss'}$ 是在 π 下从 s 出发恰好用 k 步转移到 s' 的概率。

证明

首先，对任意 $s \in \mathcal{S}$ ：

$$\begin{aligned} \nabla_{\boldsymbol{\theta}} v_\pi(s) &= \nabla_{\boldsymbol{\theta}} \left[\sum_{a \in \mathcal{A}} \pi(a|s, \boldsymbol{\theta}) q_\pi(s, a) \right] \\ &= \sum_{a \in \mathcal{A}} [\nabla_{\boldsymbol{\theta}} \pi(a|s, \boldsymbol{\theta}) q_\pi(s, a) + \pi(a|s, \boldsymbol{\theta}) \nabla_{\boldsymbol{\theta}} q_\pi(s, a)]; \end{aligned}$$

其中动作价值为：

$$q_\pi(s, a) = r(s, a) + \gamma \sum_{s' \in \mathcal{S}} p(s'|s, a) v_\pi(s').$$

由于 $r(s, a) = \sum_r r p(r|s, a)$ 独立于 $\boldsymbol{\theta}$ ，有：

$$\nabla_{\boldsymbol{\theta}} q_\pi(s, a) = 0 + \gamma \sum_{s' \in \mathcal{S}} p(s'|s, a) \nabla_{\boldsymbol{\theta}} v_\pi(s').$$

代入得：

$$\begin{aligned}\nabla_{\boldsymbol{\theta}} v_{\pi}(s) &= \sum_{a \in \mathcal{A}} \left[\nabla_{\boldsymbol{\theta}} \pi(a|s, \boldsymbol{\theta}) q_{\pi}(s, a) + \pi(a|s, \boldsymbol{\theta}) \gamma \sum_{s' \in \mathcal{S}} p(s'|s, a) \nabla_{\boldsymbol{\theta}} v_{\pi}(s') \right] \\ &= \sum_{a \in \mathcal{A}} \nabla_{\boldsymbol{\theta}} \pi(a|s, \boldsymbol{\theta}) q_{\pi}(s, a) + \gamma \sum_{a \in \mathcal{A}} \pi(a|s, \boldsymbol{\theta}) \sum_{s' \in \mathcal{S}} p(s'|s, a) \nabla_{\boldsymbol{\theta}} v_{\pi}(s').\end{aligned}$$

值得注意的是， $\nabla_{\boldsymbol{\theta}} v_{\pi}$ 出现在上式的两边。下面使用矩阵-向量形式求解。令

$$\mathbf{u}(s) := \sum_{a \in \mathcal{A}} \nabla_{\boldsymbol{\theta}} \pi(a|s, \boldsymbol{\theta}) q_{\pi}(s, a).$$

由于

$$\sum_{a \in \mathcal{A}} \pi(a|s, \boldsymbol{\theta}) \sum_{s' \in \mathcal{S}} p(s'|s, a) \nabla_{\boldsymbol{\theta}} v_{\pi}(s') = \sum_{s' \in \mathcal{S}} p(s'|s) \nabla_{\boldsymbol{\theta}} v_{\pi}(s') = \sum_{s' \in \mathcal{S}} [\mathbf{P}_{\pi}]_{ss'} \nabla_{\boldsymbol{\theta}} v_{\pi}(s'),$$

上式可以写成矩阵-向量形式：

$$\nabla_{\boldsymbol{\theta}} \mathbf{v}_{\pi} = \mathbf{u} + \gamma(\mathbf{P}_{\pi} \otimes \mathbf{I}_m) \nabla_{\boldsymbol{\theta}} \mathbf{v}_{\pi};$$

其中 $n = |\mathcal{S}|$ ， m 是参数向量 $\boldsymbol{\theta}$ 的维数， $\otimes$ 是 Kronecker 积。该方程是关于 $\nabla_{\boldsymbol{\theta}} \mathbf{v}_{\pi}$ 的线性方程，可解为：

$$\nabla_{\boldsymbol{\theta}} \mathbf{v}_{\pi} = (\mathbf{I}_{nm} - \gamma \mathbf{P}_{\pi} \otimes \mathbf{I}_m)^{-1} \mathbf{u} = [(\mathbf{I}_n - \gamma \mathbf{P}_{\pi})^{-1} \otimes \mathbf{I}_m] \mathbf{u}.$$

对任意状态 s ，有：

$$\nabla_{\boldsymbol{\theta}} v_{\pi}(s) = \sum_{s' \in \mathcal{S}} [(\mathbf{I}_n - \gamma \mathbf{P}_{\pi})^{-1}]_{ss'} \mathbf{u}(s') = \sum_{s' \in \mathcal{S}} [(\mathbf{I}_n - \gamma \mathbf{P}_{\pi})^{-1}]_{ss'} \sum_{a \in \mathcal{A}} \nabla_{\boldsymbol{\theta}} \pi(a|s', \boldsymbol{\theta}) q_{\pi}(s', a).$$

由于 $(\mathbf{I}_n - \gamma \mathbf{P}_{\pi})^{-1} = \mathbf{I} + \gamma \mathbf{P}_{\pi} + \gamma^2 \mathbf{P}_{\pi}^2 + \dots$ ， $[(\mathbf{I}_n - \gamma \mathbf{P}_{\pi})^{-1}]_{ss'}$ 表示从 s 转移到 s' 的折扣总概率。记 $\text{Pr}_{\pi}(s'|s) := [(\mathbf{I}_n - \gamma \mathbf{P}_{\pi})^{-1}]_{ss'}$ ，即得 (8)。

借助引理 9.2 的结果，我们可以推导 $\bar{v}_{\pi}^0$ 的梯度。

定理 9.2 折扣情形下 $\bar{v}_{\pi}^0$ 的梯度

在折扣情形 ($\gamma \in (0, 1)$) 下， $\bar{v}_{\pi}^0 = \mathbf{d}_0^T \mathbf{v}_{\pi}$ 的梯度为：

$$\nabla_{\boldsymbol{\theta}} \bar{v}_{\pi}^0 = \mathbb{E}[\nabla_{\boldsymbol{\theta}} \ln \pi(A|S, \boldsymbol{\theta}) q_{\pi}(S, A)];$$

其中 $S \sim \eta_{\pi}$ 且 $A \sim \pi(S, \boldsymbol{\theta})$ 。这里状态分布 η_{π} 为：

$$\eta_{\pi}(s) = \sum_{s' \in \mathcal{S}} d_0(s') \text{Pr}_{\pi}(s|s'), \quad s \in \mathcal{S};$$

其中 $\text{Pr}_{\pi}(s|s') = \sum_{k=0}^{\infty} \gamma^k [\mathbf{P}_{\pi}^k]_{s's} = [(\mathbf{I} - \gamma \mathbf{P}_{\pi})^{-1}]_{s's}$ 是在策略 π 下从 s' 转移到 s 的折扣总概率。

证明

由于 $d_0(s)$ 独立于 π , 有:

$$\nabla_{\theta} \bar{v}_{\pi}^0 = \nabla_{\theta} \sum_{s \in \mathcal{S}} d_0(s) v_{\pi}(s) = \sum_{s \in \mathcal{S}} d_0(s) \nabla_{\theta} v_{\pi}(s).$$

将引理 9.2 中 $\nabla_{\theta} v_{\pi}(s)$ 的表达式代入:

$$\begin{aligned} \nabla_{\theta} \bar{v}_{\pi}^0 &= \sum_{s \in \mathcal{S}} d_0(s) \nabla_{\theta} v_{\pi}(s) = \sum_{s \in \mathcal{S}} d_0(s) \sum_{s' \in \mathcal{S}} \Pr_{\pi}(s'|s) \sum_{a \in \mathcal{A}} \nabla_{\theta} \pi(a|s', \theta) q_{\pi}(s', a) \\ &= \sum_{s' \in \mathcal{S}} \left(\sum_{s \in \mathcal{S}} d_0(s) \Pr_{\pi}(s'|s) \right) \sum_{a \in \mathcal{A}} \nabla_{\theta} \pi(a|s', \theta) q_{\pi}(s', a) \\ &:= \sum_{s' \in \mathcal{S}} \eta_{\pi}(s') \sum_{a \in \mathcal{A}} \nabla_{\theta} \pi(a|s', \theta) q_{\pi}(s', a). \end{aligned}$$

然后利用 $\nabla_{\theta} \pi(a|s, \theta) = \pi(a|s, \theta) \nabla_{\theta} \ln \pi(a|s, \theta)$ 即得最终形式。

借助引理 9.1 和引理 9.2, 可以推导 $\bar{r}_{\pi}$ 和 $\bar{v}_{\pi}$ 的梯度。

定理 9.3 折扣情形下 $\bar{r}_{\pi}$ 和 $\bar{v}_{\pi}$ 的梯度

在折扣情形 ($\gamma \in (0, 1)$) 下, $\bar{r}_{\pi}$ 和 $\bar{v}_{\pi}$ 的梯度为:

$$\begin{aligned} \nabla_{\theta} \bar{r}_{\pi} &= (1 - \gamma) \nabla_{\theta} \bar{v}_{\pi} \approx \sum_{s \in \mathcal{S}} d_{\pi}(s) \sum_{a \in \mathcal{A}} \nabla_{\theta} \pi(a|s, \theta) q_{\pi}(s, a) \\ &= \mathbb{E}[\nabla_{\theta} \ln \pi(A|S, \theta) q_{\pi}(S, A)]; \end{aligned}$$

其中 $S \sim d_{\pi}$, $A \sim \pi(S, \theta)$ 。该近似在 γ 越接近 1 时越精确。

证明

由 $\bar{v}_{\pi}$ 的定义:

$$\nabla_{\theta} \bar{v}_{\pi} = \nabla_{\theta} \sum_{s \in \mathcal{S}} d_{\pi}(s) v_{\pi}(s) = \sum_{s \in \mathcal{S}} \nabla_{\theta} d_{\pi}(s) v_{\pi}(s) + \sum_{s \in \mathcal{S}} d_{\pi}(s) \nabla_{\theta} v_{\pi}(s).$$

该方程包含两项。一方面, 代入 $\nabla_{\theta} v_{\pi}$ 的矩阵-向量解到第二项:

$$\sum_{s \in \mathcal{S}} d_{\pi}(s) \nabla_{\theta} v_{\pi}(s) = (\mathbf{d}_{\pi}^T \otimes \mathbf{I}_m) \nabla_{\theta} \mathbf{v}_{\pi} = [\mathbf{d}_{\pi}^T (\mathbf{I}_n - \gamma \mathbf{P}_{\pi})^{-1} \otimes \mathbf{I}_m] \mathbf{u}.$$

注意到 $\mathbf{d}_{\pi}^T (\mathbf{I}_n - \gamma \mathbf{P}_{\pi})^{-1} = \frac{1}{1-\gamma} \mathbf{d}_{\pi}^T$ (可通过在方程两边右乘 $(\mathbf{I}_n - \gamma \mathbf{P}_{\pi})$ 验证)。因此:

$$\sum_{s \in \mathcal{S}} d_{\pi}(s) \nabla_{\theta} v_{\pi}(s) = \frac{1}{1-\gamma} (\mathbf{d}_{\pi}^T \otimes \mathbf{I}_m) \mathbf{u} = \frac{1}{1-\gamma} \sum_{s \in \mathcal{S}} d_{\pi}(s) \sum_{a \in \mathcal{A}} \nabla_{\theta} \pi(a|s, \theta) q_{\pi}(s, a).$$

另一方面, 第一项涉及 $\nabla_{\theta} d_{\pi}$ 。然而, 由于第二项包含 $\frac{1}{1-\gamma}$, 当 $\gamma \rightarrow 1$ 时第二项占主导地位, 第一项可以忽略。因此:

$$\nabla_{\theta} \bar{v}_{\pi} \approx \frac{1}{1-\gamma} \sum_{s \in \mathcal{S}} d_{\pi}(s) \sum_{a \in \mathcal{A}} \nabla_{\theta} \pi(a|s, \theta) q_{\pi}(s, a).$$

进而由 $\bar{r}_{\pi} = (1 - \gamma) \bar{v}_{\pi}$ 得:

$$\nabla_{\theta} \bar{r}_{\pi} = (1 - \gamma) \nabla_{\theta} \bar{v}_{\pi} \approx \sum_{s \in \mathcal{S}} d_{\pi}(s) \sum_{a \in \mathcal{A}} \nabla_{\theta} \pi(a|s, \theta) q_{\pi}(s, a) = \mathbb{E}[\nabla_{\theta} \ln \pi(A|S, \theta) q_{\pi}(S, A)].$$

该近似要求当 $\gamma \rightarrow 1$ 时第一项不趋于无穷。

9.3.2 无折扣情形下的梯度推导

下面展示在无折扣情形 ($\gamma = 1$) 下如何计算指标的梯度。虽然本书此前一直只考虑折扣情形, 但平均奖励 $\bar{r}_\pi$ 的定义对折扣和非折扣情形都有效。折扣情形下 $\bar{r}_\pi$ 的梯度是一个近似, 而无折扣情形下的梯度则更为优美。

状态价值与 *Poisson* 方程

在无折扣情形下, 需要重新定义状态和动作价值。由于奖励的无折扣和 $\mathbb{E}[R_{t+1} + R_{t+2} + R_{t+3} + \dots | S_t = s]$ 可能发散, 状态和动作价值以一种特殊方式定义:

$$v_\pi(s) := \mathbb{E}[(R_{t+1} - \bar{r}_\pi) + (R_{t+2} - \bar{r}_\pi) + (R_{t+3} - \bar{r}_\pi) + \dots | S_t = s],$$

$$q_\pi(s, a) := \mathbb{E}[(R_{t+1} - \bar{r}_\pi) + (R_{t+2} - \bar{r}_\pi) + (R_{t+3} - \bar{r}_\pi) + \dots | S_t = s, A_t = a];$$

其中 $\bar{r}_\pi$ 是平均奖励, 在给定 π 时确定。文献中 $v_\pi(s)$ 有不同的名称, 如差分奖励 (differential reward) 或偏差 (bias)。可以验证上述定义的状态价值满足以下类似贝尔曼方程的方程:

$$v_\pi(s) = \sum_a \pi(a|s, \theta) \left[\sum_r p(r|s, a)(r - \bar{r}_\pi) + \sum_{s'} p(s'|s, a) v_\pi(s') \right].$$

由于 $v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a|s, \theta) q_\pi(s, a)$, 有 $q_\pi(s, a) = \sum_r p(r|s, a)(r - \bar{r}_\pi) + \sum_{s'} p(s'|s, a) v_\pi(s')$ 。该方程的矩阵-向量形式为:

$$\mathbf{v}_\pi = \mathbf{r}_\pi - \bar{r}_\pi \mathbf{1}_n + \mathbf{P}_\pi \mathbf{v}_\pi; \quad (9)$$

其中 $\mathbf{1}_n = [1, \dots, 1]^T \in \mathbb{R}^n$ 。方程 (9) 类似贝尔曼方程, 有一个特定的名称叫做 **Poisson 方程**。

如何从 Poisson 方程中解出 $\mathbf{v}_\pi$? 答案在以下定理中给出。

定理 9.4 Poisson 方程的解

令

$$\mathbf{v}_\pi^* = (\mathbf{I}_n - \mathbf{P}_\pi + \mathbf{1}_n \mathbf{d}_\pi^T)^{-1} \mathbf{r}_\pi.$$

则 $\mathbf{v}_\pi^*$ 是 Poisson 方程 (9) 的一个解。此外, Poisson 方程的任意解都具有以下形式:

$$\mathbf{v}_\pi = \mathbf{v}_\pi^* + c \mathbf{1}_n;$$

其中 $c \in \mathbb{R}$ 。

该定理表明 Poisson 方程的解可能不唯一。

证明

我们分三步证明。

步骤 1: 证明 $\mathbf{v}_\pi^*$ 是 Poisson 方程的一个解。

为简单起见, 令 $\mathbf{A} := \mathbf{I}_n - \mathbf{P}_\pi + \mathbf{1}_n \mathbf{d}_\pi^T$ 。则 $\mathbf{v}_\pi^* = \mathbf{A}^{-1} \mathbf{r}_\pi$ 。 $\mathbf{A}$ 的可逆性将在步骤 3 中证明。将 $\mathbf{v}_\pi^* = \mathbf{A}^{-1} \mathbf{r}_\pi$ 代入 (9) 得:

$$\mathbf{A}^{-1} \mathbf{r}_\pi = \mathbf{r}_\pi - \mathbf{1}_n \mathbf{d}_\pi^T \mathbf{r}_\pi + \mathbf{P}_\pi \mathbf{A}^{-1} \mathbf{r}_\pi.$$

整理得 $(-\mathbf{A}^{-1} + \mathbf{I}_n - \mathbf{1}_n \mathbf{d}_\pi^T + \mathbf{P}_\pi \mathbf{A}^{-1}) \mathbf{r}_\pi = 0$, 即 $(-\mathbf{I}_n + \mathbf{A}^{-1} \mathbf{1}_n \mathbf{d}_\pi^T \mathbf{A} + \mathbf{P}_\pi) \mathbf{A}^{-1} \mathbf{r}_\pi = 0$ 。由于 $-\mathbf{I}_n + \mathbf{A}^{-1} \mathbf{1}_n \mathbf{d}_\pi^T (\mathbf{I}_n - \mathbf{P}_\pi + \mathbf{1}_n \mathbf{d}_\pi^T) + \mathbf{P}_\pi = \mathbf{0}$, 得证。

步骤 2: 解的通用表达式。

将 $\bar{r}_\pi = \mathbf{d}_\pi^T \mathbf{r}_\pi$ 代入 (9) 得:

$$\mathbf{v}_\pi = \mathbf{r}_\pi - \mathbf{1}_n \mathbf{d}_\pi^T \mathbf{r}_\pi + \mathbf{P}_\pi \mathbf{v}_\pi,$$

因此:

$$(\mathbf{I}_n - \mathbf{P}_\pi) \mathbf{v}_\pi = (\mathbf{I}_n - \mathbf{1}_n \mathbf{d}_\pi^T) \mathbf{r}_\pi.$$

注意到 $\mathbf{I}_n - \mathbf{P}_\pi$ 是奇异的, 因为 $(\mathbf{I}_n - \mathbf{P}_\pi) \mathbf{1}_n = 0$ 。因此解不唯一: 若 $\mathbf{v}_\pi^*$ 是一个解, 则 $\mathbf{v}_\pi^* + \mathbf{x}$ 对任意 $\mathbf{x} \in \text{Null}(\mathbf{I}_n - \mathbf{P}_\pi)$ 也是一个解。当 $\mathbf{P}_\pi$ 不可约时, $\text{Null}(\mathbf{I}_n - \mathbf{P}_\pi) = \text{span}\{\mathbf{1}_n\}$ 。因此 Poisson 方程的任意解具有 $\mathbf{v}_\pi^* + c \mathbf{1}_n$ 的形式, 其中 $c \in \mathbb{R}$ 。

步骤 3: 证明 $\mathbf{A} = \mathbf{I}_n - \mathbf{P}_\pi + \mathbf{1}_n \mathbf{d}_\pi^T$ 可逆。

首先给出一些基本事实 (不在此处证明)。设 $\rho(\mathbf{M})$ 是矩阵 $\mathbf{M}$ 的谱半径。则 $\mathbf{I} - \mathbf{M}$ 可逆当且仅当 $\rho(\mathbf{M}) < 1$ 。此外, $\rho(\mathbf{M}) < 1$ 当且仅当 $\lim_{k \rightarrow \infty} \mathbf{M}^k = 0$ 。

基于以上事实, 下面证明 $\lim_{k \rightarrow \infty} (\mathbf{P}_\pi - \mathbf{1}_n \mathbf{d}_\pi^T)^k \rightarrow 0$ 。注意到:

$$(\mathbf{P}_\pi - \mathbf{1}_n \mathbf{d}_\pi^T)^k = \mathbf{P}_\pi^k - \mathbf{1}_n \mathbf{d}_\pi^T, \quad k \geq 1;$$

这可以通过归纳法证明。由于 d_π 是状态的平稳分布, 有 $\lim_{k \rightarrow \infty} \mathbf{P}_\pi^k = \mathbf{1}_n \mathbf{d}_\pi^T$ 。因此:

$$\lim_{k \rightarrow \infty} (\mathbf{P}_\pi - \mathbf{1}_n \mathbf{d}_\pi^T)^k = \lim_{k \rightarrow \infty} \mathbf{P}_\pi^k - \mathbf{1}_n \mathbf{d}_\pi^T = 0.$$

因此 $\rho(\mathbf{P}_\pi - \mathbf{1}_n \mathbf{d}_\pi^T) < 1$, $\mathbf{I}_n - (\mathbf{P}_\pi - \mathbf{1}_n \mathbf{d}_\pi^T)$ 可逆, 且其逆为:

$$(\mathbf{I}_n - (\mathbf{P}_\pi - \mathbf{1}_n \mathbf{d}_\pi^T))^{-1} = \sum_{k=0}^{\infty} (\mathbf{P}_\pi - \mathbf{1}_n \mathbf{d}_\pi^T)^k = \mathbf{I}_n + \sum_{k=1}^{\infty} (\mathbf{P}_\pi^k - \mathbf{1}_n \mathbf{d}_\pi^T).$$

梯度的推导

虽然如定理 9.4 所示 $\mathbf{v}_\pi$ 在无折扣情形下不唯一, 但 $\bar{r}_\pi$ 的值是唯一的。具体而言, 由 Poisson 方程:

$$\bar{r}_\pi \mathbf{1}_n = \mathbf{r}_\pi + (\mathbf{P}_\pi - \mathbf{I}_n) \mathbf{v}_\pi = \mathbf{r}_\pi + (\mathbf{P}_\pi - \mathbf{I}_n) (\mathbf{v}_\pi^* + c \mathbf{1}_n) = \mathbf{r}_\pi + (\mathbf{P}_\pi - \mathbf{I}_n) \mathbf{v}_\pi^*.$$

值得注意的是, 未定值 c 被消去了, 因此 $\bar{r}_\pi$ 是唯一的。因此可以计算无折扣情形下 $\bar{r}_\pi$ 的梯度。

定理 9.5 无折扣情形下 $\bar{r}_\pi$ 的梯度

在无折扣情形下, 平均奖励 $\bar{r}_\pi$ 的梯度为:

$$\begin{aligned} \nabla_{\boldsymbol{\theta}} \bar{r}_\pi &= \sum_{s \in \mathcal{S}} d_\pi(s) \sum_{a \in \mathcal{A}} \nabla_{\boldsymbol{\theta}} \pi(a|s, \boldsymbol{\theta}) q_\pi(s, a) \\ &= \mathbb{E}[\nabla_{\boldsymbol{\theta}} \ln \pi(A|S, \boldsymbol{\theta}) q_\pi(S, A)]; \end{aligned}$$

其中 $S \sim d_\pi$, $A \sim \pi(S, \boldsymbol{\theta})$ 。

与定理 9.3 所示的折扣情形相比, 无折扣情形下 $\bar{r}_\pi$ 的梯度更为优美, 因为上式是严格成立的, 且 S 服从平稳分布。

证明

首先, 由 $v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a|s, \boldsymbol{\theta}) q_\pi(s, a)$:

$$\begin{aligned}\nabla_{\boldsymbol{\theta}} v_\pi(s) &= \nabla_{\boldsymbol{\theta}} \left[\sum_{a \in \mathcal{A}} \pi(a|s, \boldsymbol{\theta}) q_\pi(s, a) \right] \\ &= \sum_{a \in \mathcal{A}} [\nabla_{\boldsymbol{\theta}} \pi(a|s, \boldsymbol{\theta}) q_\pi(s, a) + \pi(a|s, \boldsymbol{\theta}) \nabla_{\boldsymbol{\theta}} q_\pi(s, a)];\end{aligned}$$

其中动作价值满足:

$$q_\pi(s, a) = \sum_r p(r|s, a)(r - \bar{r}_\pi) + \sum_{s'} p(s'|s, a) v_\pi(s') = r(s, a) - \bar{r}_\pi + \sum_{s'} p(s'|s, a) v_\pi(s').$$

由于 $r(s, a) = \sum_r r p(r|s, a)$ 独立于 $\boldsymbol{\theta}$, 有:

$$\nabla_{\boldsymbol{\theta}} q_\pi(s, a) = 0 - \nabla_{\boldsymbol{\theta}} \bar{r}_\pi + \sum_{s' \in \mathcal{S}} p(s'|s, a) \nabla_{\boldsymbol{\theta}} v_\pi(s').$$

代入得:

$$\nabla_{\boldsymbol{\theta}} v_\pi(s) = \sum_{a \in \mathcal{A}} \nabla_{\boldsymbol{\theta}} \pi(a|s, \boldsymbol{\theta}) q_\pi(s, a) - \nabla_{\boldsymbol{\theta}} \bar{r}_\pi + \sum_{a \in \mathcal{A}} \pi(a|s, \boldsymbol{\theta}) \sum_{s' \in \mathcal{S}} p(s'|s, a) \nabla_{\boldsymbol{\theta}} v_\pi(s').$$

令 $\mathbf{u}(s) := \sum_{a \in \mathcal{A}} \nabla_{\boldsymbol{\theta}} \pi(a|s, \boldsymbol{\theta}) q_\pi(s, a)$ 。上式可以写成矩阵-向量形式:

$$\nabla_{\boldsymbol{\theta}} \mathbf{v}_\pi = \mathbf{u} - \mathbf{1}_n \otimes \nabla_{\boldsymbol{\theta}} \bar{r}_\pi + (\mathbf{P}_\pi \otimes \mathbf{I}_m) \nabla_{\boldsymbol{\theta}} \mathbf{v}_\pi;$$

其中 $n = |\mathcal{S}|$, m 是 $\boldsymbol{\theta}$ 的维数, $\otimes$ 是 Kronecker 积。整理得:

$$\mathbf{1}_n \otimes \nabla_{\boldsymbol{\theta}} \bar{r}_\pi = \mathbf{u} + (\mathbf{P}_\pi \otimes \mathbf{I}_m) \nabla_{\boldsymbol{\theta}} \mathbf{v}_\pi - \nabla_{\boldsymbol{\theta}} \mathbf{v}_\pi.$$

两边左乘 $\mathbf{d}_\pi^T \otimes \mathbf{I}_m$:

$$\begin{aligned}(\mathbf{d}_\pi^T \mathbf{1}_n) \otimes \nabla_{\boldsymbol{\theta}} \bar{r}_\pi &= (\mathbf{d}_\pi^T \otimes \mathbf{I}_m) \mathbf{u} + (\mathbf{d}_\pi^T \mathbf{P}_\pi \otimes \mathbf{I}_m) \nabla_{\boldsymbol{\theta}} \mathbf{v}_\pi - (\mathbf{d}_\pi^T \otimes \mathbf{I}_m) \nabla_{\boldsymbol{\theta}} \mathbf{v}_\pi \\ &= (\mathbf{d}_\pi^T \otimes \mathbf{I}_m) \mathbf{u}.\end{aligned}$$

这推出:

$$\nabla_{\boldsymbol{\theta}} \bar{r}_\pi = (\mathbf{d}_\pi^T \otimes \mathbf{I}_m) \mathbf{u} = \sum_{s \in \mathcal{S}} d_\pi(s) \mathbf{u}(s) = \sum_{s \in \mathcal{S}} d_\pi(s) \sum_{a \in \mathcal{A}} \nabla_{\boldsymbol{\theta}} \pi(a|s, \boldsymbol{\theta}) q_\pi(s, a).$$

证明完毕。

9.4 蒙特卡洛策略梯度 (REINFORCE)

有了定理 9.1 给出的梯度, 下面展示如何使用基于梯度的方法优化指标以获得最优策略。

最大化 $J(\boldsymbol{\theta})$ 的梯度上升算法为:

$$\begin{aligned}\boldsymbol{\theta}_{t+1} &= \boldsymbol{\theta}_t + \alpha \nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}_t) \\ &= \boldsymbol{\theta}_t + \alpha \mathbb{E}[\nabla_{\boldsymbol{\theta}} \ln \pi(A|S, \boldsymbol{\theta}_t) q_\pi(S, A)];\end{aligned}\tag{10}$$

其中 $\alpha > 0$ 是常学习率。由于 (10) 中的真实梯度未知, 可以用随机梯度替代真实梯度, 得到以下算法:

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t + \alpha \nabla_{\boldsymbol{\theta}} \ln \pi(a_t|s_t, \boldsymbol{\theta}_t) q_t(s_t, a_t);\tag{11}$$

其中 $q_t(s_t, a_t)$ 是 $q_\pi(s_t, a_t)$ 的一个近似。若 $q_t(s_t, a_t)$ 通过蒙特卡洛估计获得，则该算法称为 **REINFORCE** 或**蒙特卡洛策略梯度**，是最早也是最简单的策略梯度算法之一。

(11) 中的算法非常重要，因为许多其他策略梯度算法都可以通过扩展该算法得到。下面更仔细地考察 (11) 的解释。

由于 $\nabla_{\theta} \ln \pi(a_t|s_t, \theta_t) = \frac{\nabla_{\theta} \pi(a_t|s_t, \theta_t)}{\pi(a_t|s_t, \theta_t)}$ ，可以将 (11) 改写为：

$$\theta_{t+1} = \theta_t + \alpha \underbrace{\left(\frac{q_t(s_t, a_t)}{\pi(a_t|s_t, \theta_t)} \right)}_{\beta_t} \nabla_{\theta} \pi(a_t|s_t, \theta_t);$$

可进一步简写为：

$$\theta_{t+1} = \theta_t + \alpha \beta_t \nabla_{\theta} \pi(a_t|s_t, \theta_t). \quad (12)$$

从该方程可以看出两个重要的解释。

- **第一**，由于 (12) 是一个简单的梯度上升算法，可以得到以下观察：
 - 若 $\beta_t \geq 0$ ，则选择 (s_t, a_t) 的概率被增强。即：

$$\pi(a_t|s_t, \theta_{t+1}) \geq \pi(a_t|s_t, \theta_t).$$

β_t 越大，增强效果越强。

- 若 $\beta_t < 0$ ，则选择 (s_t, a_t) 的概率减小。即：

$$\pi(a_t|s_t, \theta_{t+1}) < \pi(a_t|s_t, \theta_t).$$

上述观察的证明如下。当 $\theta_{t+1} - \theta_t$ 足够小时，由 Taylor 展开：

$$\begin{aligned} \pi(a_t|s_t, \theta_{t+1}) &\approx \pi(a_t|s_t, \theta_t) + (\nabla_{\theta} \pi(a_t|s_t, \theta_t))^T (\theta_{t+1} - \theta_t) \\ &= \pi(a_t|s_t, \theta_t) + \alpha \beta_t (\nabla_{\theta} \pi(a_t|s_t, \theta_t))^T (\nabla_{\theta} \pi(a_t|s_t, \theta_t)) \\ &= \pi(a_t|s_t, \theta_t) + \alpha \beta_t \|\nabla_{\theta} \pi(a_t|s_t, \theta_t)\|_2^2. \end{aligned}$$

显然，当 $\beta_t \geq 0$ 时 $\pi(a_t|s_t, \theta_{t+1}) \geq \pi(a_t|s_t, \theta_t)$ ，当 $\beta_t < 0$ 时 $\pi(a_t|s_t, \theta_{t+1}) < \pi(a_t|s_t, \theta_t)$ 。

- **第二**，由于 $\beta_t = \frac{q_t(s_t, a_t)}{\pi(a_t|s_t, \theta_t)}$ 的表达式，该算法可以在一定程度上平衡探索与利用：
 - β_t 与 $q_t(s_t, a_t)$ 成正比。因此，若 (s_t, a_t) 的动作价值大，则 $\pi(a_t|s_t, \theta_t)$ 被增强，使得选择 a_t 的概率增加。因此，该算法试图**利用**价值更大的动作。
 - 当 $q_t(s_t, a_t) > 0$ 时， β_t 与 $\pi(a_t|s_t, \theta_t)$ 成反比。因此，若选择 a_t 的概率小，则 $\pi(a_t|s_t, \theta_t)$ 被增强，使得选择 a_t 的概率增加。因此，该算法试图**探索**概率较低的动作。

此外，由于 (11) 使用样本来近似 (10) 中的真实梯度，理解应如何获取样本非常重要。

- **如何采样 S ?** 在真实梯度 $\mathbb{E}[\nabla_{\theta} \ln \pi(A|S, \theta_t) q_\pi(S, A)]$ 中的 S 应服从分布 η ，该分布要么是平稳分布 d_π ，要么是 (7) 中的折扣总概率分布 η_π 。 d_π 和 η_π 都代表了在 π 下表现出的长期行为。
- **如何采样 A ?** 在 $\mathbb{E}[\nabla_{\theta} \ln \pi(A|S, \theta_t) q_\pi(S, A)]$ 中的 A 应服从 $\pi(A|S, \theta)$ 的分布。理想的采样 A 的方法是按照 $\pi(a_t|s_t, \theta_t)$ 选择 a_t 。因此，策略梯度算法是**同策略 (on-policy)** 的。

不幸的是，由于样本利用效率低，在实践中并未严格遵循 S 和 A 采样的理想方式。一个样本效率更高的 (11) 实现如算法 9.1 所示。在该实现中，首先生成一个遵循 $\pi(\theta)$ 的回合，然后利用该回合中的每个经验样本多次更新 θ 。

定义

算法 9.1: 蒙特卡洛策略梯度 (REINFORCE)

初始化: 初始参数 θ ; $\gamma \in (0, 1)$; $\alpha > 0$ 。

目标: 学习最优策略以最大化 $J(\theta)$ 。

对每个回合, 执行:

生成一个回合 $\{s_0, a_0, r_1, \dots, s_{T-1}, a_{T-1}, r_T\}$ 遵循 $\pi(\theta)$ 。

对 $t = 0, 1, \dots, T-1$:

价值更新: $q_t(s_t, a_t) = \sum_{k=t+1}^T \gamma^{k-t-1} r_k$

策略更新: $\theta \leftarrow \theta + \alpha \nabla_{\theta} \ln \pi(a_t | s_t, \theta) q_t(s_t, a_t)$

9.5 本章小结

本章介绍了策略梯度方法, 它是许多现代强化学习算法的基础。策略梯度方法是基于策略的 (policy-based) 方法。这是本书的一大进步, 因为此前所有章节的方法都是基于价值的 (value-based) 方法。策略梯度方法的基本思想很简单: 选择一个合适的标量指标, 然后通过梯度上升算法优化它。

策略梯度方法最复杂的部分是指标梯度的推导。这是因为我们必须区分各种不同指标和折扣/非折扣情形下的不同场景。幸运的是, 不同场景下的梯度表达式是相似的。因此, 我们将这些表达式总结在定理 9.1 (策略梯度定理) 中, 这是本章最重要的理论结果。对大多数读者来说, 了解该定理就足够了。其证明较为复杂, 并非要求所有读者都学习。

备注

(11) 中的策略梯度算法必须被正确理解, 因为它是许多高级策略梯度算法的基础。在下一章中, 该算法将被扩展为另一种重要的策略梯度方法——Actor-Critic。

9.6 常见问题解答

• Q: 策略梯度方法的基本思想是什么?

A: 基本思想很简单。即定义一个合适的标量指标, 推导其梯度, 然后使用梯度上升方法优化该指标。关于该方法最重要的理论结果是定理 9.1 中给出的策略梯度。

• Q: 策略梯度方法最复杂的部分是什么?

A: 策略梯度方法的基本思想很简单, 但梯度的推导过程相当复杂。这是因为我们必须区分许多不同的场景。每个场景下的数学推导过程都不简单。对大多数读者来说, 熟悉定理 9.1 的结果就足够了, 无需了解其证明。

• Q: 策略梯度方法中应该使用什么指标?

A: 本章介绍了三种常见指标: $\bar{v}_{\pi}$ 、 $\bar{v}_{\pi}^0$ 和 $\bar{r}_{\pi}$ 。由于它们都导致相似的策略梯度, 因此都可以在策略梯度方法中采用。更重要的是, (1) 和 (4) 中的表达式在文献中经常出现。

• Q: 为什么策略梯度中包含自然对数函数?

A: 引入自然对数函数是为了将梯度表示为期望值的形式。这样, 我们可以用随机梯度来近似真实梯度。

• Q: 为什么在推导策略梯度时需要研究无折扣情形?

A: 平均奖励 $\bar{r}_{\pi}$ 的定义对折扣和无折扣情形都有效。折扣情形下 $\bar{r}_{\pi}$ 的梯度是一个近似, 而无折扣情形下的梯度更为优美——它是严格成立的, 且状态服从平稳分布。

• Q: (11) 中的策略梯度算法在数学上做了什么?

A: 为了更好地理解该算法, 建议读者考察其紧凑形式 (12)。该式清楚地表明它是一个用于更新

$\pi(a_t|s_t, \theta_t)$ 值的梯度上升算法。即当有一个样本 (s_t, a_t) 时, 策略可以被更新, 使得 $\pi(a_t|s_t, \theta_{t+1}) \geq \pi(a_t|s_t, \theta_t)$ 或 $\pi(a_t|s_t, \theta_{t+1}) < \pi(a_t|s_t, \theta_t)$, 具体取决于系数 β_t 的符号。

- **Q: 策略梯度方法与基于价值的方法相比有什么优势?**

A: 策略梯度方法在以下方面具有优势: (1) 它可以直接处理连续动作空间; (2) 它可以学习随机策略, 这在某些博弈场景中至关重要; (3) 它在处理大状态/动作空间时效率更高, 具有更强的泛化能力和样本利用效率; (4) 策略的参数化使得先验知识的融入更加自然。

- **Q: 什么是 REINFORCE 算法?**

A: REINFORCE 是最早也是最简单的策略梯度算法之一。它使用蒙特卡洛方法来估计 $q_t(s_t, a_t)$, 即用完整的回报 $G_t = \sum_{k=t+1}^T \gamma^{k-t-1} r_k$ 来近似动作价值, 然后沿着 $\nabla_{\theta} \ln \pi(a_t|s_t, \theta_t) G_t$ 的方向更新策略参数。

- **Q: 为什么策略梯度算法是在策略的?**

A: 因为在计算梯度时, 动作 A 必须服从策略 $\pi(\cdot|S, \theta)$ 的分布进行采样, 即智能体只能使用自己当前策略产生的数据来更新策略, 这就是在策略学习的本质。